

ANÁLISIS DE COMPONENTES PRINCIPALES

1. REPASO⊙ VALORES PROPIOS: λ_l \underline{C} matriz de $L \times L$ elementos

$$|\underline{C} - \lambda_l \underline{I}| = 0 \quad \lambda_l: \text{valores propios de } \underline{C}$$

$$l = 1, 2, \dots, L$$

Ejemplo: $\underline{C} = \begin{bmatrix} 4 & 3 \\ 1 & 2 \end{bmatrix}$

$$|\underline{C} - \lambda \underline{I}| = (4 - \lambda)(2 - \lambda) - 3 = 0$$

$$\lambda_1 = 5 \quad \lambda_2 = 1$$

⊙ VECTORES PROPIOS: \underline{v}_l

$$\underline{C} \underline{v}_l = \lambda_l \underline{v}_l \quad \underline{v}_l: \text{vectores propios}$$

$$L \times 1 \text{ elementos}$$

Como hay infinitas soluciones: s.t. $\|\underline{v}_l\| = 1$

$$\{\underline{v}_l\} \text{ son ortogonales: } \underline{v}_l^T \underline{v}_k = \begin{cases} 1 & \text{si } l=k \\ 0 & l \neq k \end{cases}$$

Se define la matriz de vectores propios:

$$\underline{A} = [\underline{v}_1 \ \underline{v}_2 \ \dots \ \underline{v}_L] \text{ de } L \times L$$

$$\underline{A} \underline{A}^T = \underline{I}$$

$$\underline{C} \underline{A} = [\lambda_1 \underline{v}_1 \ \lambda_2 \underline{v}_2 \ \dots \ \lambda_L \underline{v}_L]$$


① TRANSFORMACIONES LINEALES

$$y_1 = a_{11}x_1 + a_{12}x_2 + \dots + a_{1N}x_N$$

$$\vdots$$

$$y_N = a_{N1}x_1 + a_{N2}x_2 + \dots + a_{NN}x_N$$

$$\underline{y} = \underline{A} \underline{x}$$



- ángulo entre y_1 y y_2 no necesariamente \perp
- origen coincide
- si se necesita desplazamiento agregar + a/c en cada fila

80 años
ibm chile

① PROMEDIO Y VARIANZA

$$\underline{x} = [x_1 \ x_2 \ \dots \ x_N]^T$$

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\sigma_x = \frac{1}{N-1} \sum_{i=1}^N (\bar{x} - x_i)^2 \quad \frac{1}{N-1} : \text{unbiased estimator} \rightarrow \text{ver Anexo}$$

① COVARIANZA

$$\begin{matrix} \underline{X} \\ \uparrow \\ N \times L \end{matrix} = \begin{bmatrix} \underline{x}_1 & \underline{x}_2 & \dots & \underline{x}_L \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \end{bmatrix} = \begin{bmatrix} x_{11} & & & \\ & \ddots & & \\ & & \ddots & \\ & & & x_{NL} \end{bmatrix}$$

$$\underline{\bar{X}} = \begin{bmatrix} \bar{x}_1 & \bar{x}_2 & \dots & \bar{x}_L \end{bmatrix}$$

$$\underline{X}_0 = \begin{bmatrix} x_{11} - \bar{x}_1 & & & x_{1L} - \bar{x}_L \\ x_{21} - \bar{x}_1 & & & x_{2L} - \bar{x}_L \\ \vdots & & \ddots & \vdots \\ x_{N1} - \bar{x}_1 & & & x_{NL} - \bar{x}_L \end{bmatrix}$$

$$= \underline{X} - \underline{M}_x \text{ donde } \underline{M}_x = \begin{bmatrix} 1 & & & \\ & \ddots & & \\ & & \ddots & \\ & & & 1 \end{bmatrix} \underline{\bar{X}}$$

80 años
ibm chile

La covarianza se define como:

$$\underline{C}_x = \frac{1}{N-1} \underline{X}_0^T \underline{X}_0$$

$$= \text{cov}(\underline{X})$$

$$C_x(l, l) = \sigma_{x_l}^2$$

$C_x(l, k) = \text{covarianza de } x_l \text{ con } x_k$

> 0 dependencia lineal positiva

$= 0$ no hay dependencia

< 0 dependencia negativa

→ ver PAT03 - Covariance Visualization.m

2. TRANSFORMACIÓN KARTHUNEN-LOEVE

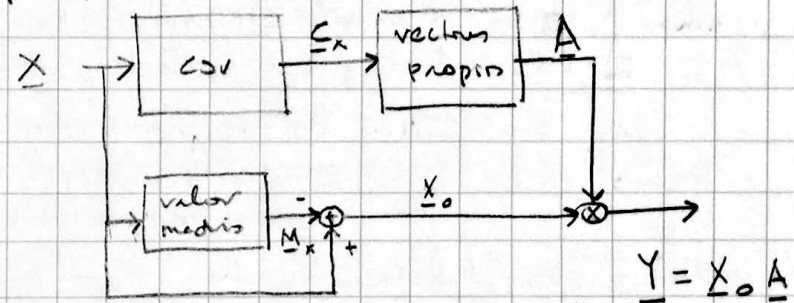
1947

$$\underline{X} = \begin{bmatrix} \underline{x}_1 & \underline{x}_2 & \dots & \underline{x}_L \end{bmatrix} \quad \underline{X}_0 = \underline{X} - \underline{M}_x$$

$N \times L \quad L \times L$

$$\underline{Y} = \underline{X}_0 \underline{A}$$

¿Qué pasa si \underline{A} es la matriz de vectores propios de \underline{C}_x ?



\underline{Y} es una transformación lineal de \underline{X}_0

Covarianza de \underline{Y}

$$\underline{C}_y = \frac{1}{N-1} \underline{Y}_0^T \underline{Y}_0$$

$$\underline{Y}_0 = \underline{Y} - \underline{M}_y$$

$$\underline{Y}_0 = \underline{Y}$$

como $\underline{Y} = \underline{X}_0 \underline{A}$ y
la media de las columnas
de \underline{X}_0 es cero entonces
 $\underline{M}_y = \underline{0}$

entonces

$$\begin{aligned}\underline{C}_Y &= \frac{1}{N-1} \underline{Y}^T \underline{Y} \\ &= \frac{1}{N-1} (\underline{X}_0 \underline{A})^T (\underline{X}_0 \underline{A}) \\ &= \frac{1}{N-1} \underline{A}^T \underline{X}_0^T \underline{X}_0 \underline{A}\end{aligned}$$

como

$$\underline{C}_X = \frac{1}{N-1} \underline{X}_0^T \underline{X}_0$$

entonces

$$\underline{C}_Y = \underline{A}^T \underline{C}_X \underline{A}$$

como \underline{A} son los valores propios de \underline{C}_X

$$\begin{aligned}\underline{C}_Y &= [\underline{v}_1 \ \underline{v}_2 \ \dots \ \underline{v}_L]^T [\lambda_1 \underline{v}_1 \ \dots \ \lambda_L \underline{v}_L] \\ &= \begin{bmatrix} \underline{v}_1^T \\ \vdots \\ \underline{v}_L^T \end{bmatrix} [\lambda_1 \underline{v}_1 \ \dots \ \lambda_L \underline{v}_L]\end{aligned}$$

$$\underline{C}_Y = \begin{bmatrix} \lambda_1 \underline{v}_1^T \underline{v}_1 & \lambda_2 \underline{v}_1^T \underline{v}_2 & \dots & \\ & \ddots & & \\ & & \lambda_L \underline{v}_L^T \underline{v}_L & \end{bmatrix}$$

$$\underline{C}_Y = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \lambda_L \end{bmatrix}$$

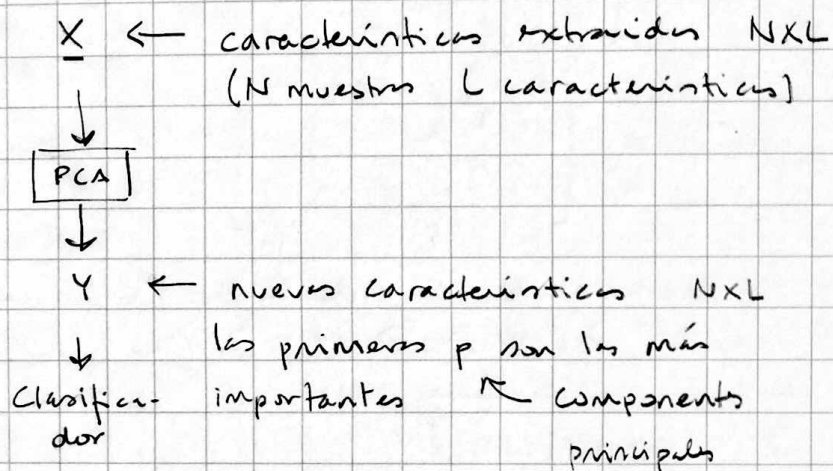
Generalmente se ordena de tal forma que $\lambda_1 > \lambda_2 > \dots > \lambda_L$

3. SIGNIFICADO

- ① \underline{Y} es una nueva representación de \underline{X} (es una transformación LINEAL de \underline{X}).
- ② Las columnas de \underline{Y} no tienen dependencia lineal $C_Y(k, l) = 0$ si $k \neq l$.
- ③ Ordenado de mayor a menor, las columnas de \underline{Y} están ordenadas por importancia.

→ ver PAT03-PCA-2D y PCA-3D.

4. APLICACIÓN A LA EXTRACCIÓN Y SELECCIÓN DE CARACTERÍSTICAS



Las decisiones se pueden tomar a partir de las primeras p características de Y

ver \rightarrow PAT03_PCA_FaceRecognition.m

- Ventajas :-
- La representación de muchas características es mucho más sencilla ya que se reduce la dimensionalidad (los gráficos son más simples).
 - La clasificación usando los primeros componentes es más simple y más rápida para el clasificador.

Desventajas : Las características PCA dependen de todos las características extraídas (es necesario extraer todas las características para obtener Y , no hay ahorro de cómputo en la extracción de X).

ver \rightarrow PAT03_PCA_DataCompression.m

$$\text{Estimación de } \sigma^2 = s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\bar{x} = \frac{1}{n} \sum x_i$$

$$E(s^2) = E \left\{ \frac{1}{n-1} \sum (x_i - \bar{x})^2 \right\}$$

$$= \frac{1}{n-1} E \left\{ \sum (\underbrace{x_i - \mu}_a + \underbrace{\mu - \bar{x}}_b)^2 \right\}$$

$$= \frac{1}{n-1} E \left\{ \sum (x_i - \mu)^2 + 2(x_i - \mu)(\mu - \bar{x}) + (\mu - \bar{x})^2 \right\}$$

$$= \frac{1}{n-1} E \left\{ \sum (x_i - \mu)^2 + 2(\mu - \bar{x}) \sum (x_i - \mu) + n(\mu - \bar{x})^2 \right\}$$

$$= \frac{1}{n-1} E \left\{ \sum (x_i - \mu)^2 - 2(-\mu + \bar{x})(n\bar{x} - n\mu) + n(\mu - \bar{x})^2 \right\}$$

$$= \frac{1}{n-1} E \left\{ \sum (x_i - \mu)^2 - 2n(\bar{x} - \mu)^2 + n(\bar{x} - \mu)^2 \right\}$$

$$= \frac{1}{n-1} E \left\{ \sum (x_i - \mu)^2 - n(\bar{x} - \mu)^2 \right\}$$

$$= \frac{1}{n-1} E \left\{ \sum E \{ (x_i - \mu)^2 \} - n E \{ (\bar{x} - \mu)^2 \} \right\}$$

$$E \{ (x_i - \mu)^2 \} = \sigma^2$$

$$\text{Var}(\bar{x}) = E \{ (\bar{x} - \mu)^2 \} = \frac{\sigma^2}{n}$$

$$E(s^2) = \frac{1}{n-1} \left(\sum \sigma^2 - n \frac{\sigma^2}{n} \right) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \sigma^2$$