


REDES NEURONALES

1




$$n_0 = 3$$

$$n_1 = 4$$

$$n_2 = 1$$

Nomenclatura (Andrew Ng)



$[l]$

a_i

l layer

i node

En el ejemplo : $l = 0, 1, 2$

$$a^{[0]} = x$$

$$a^{[1]} = \begin{bmatrix} a_1^{[1]} \\ a_2^{[1]} \\ a_3^{[1]} \end{bmatrix}$$

$$a^{[2]} = \hat{y}$$

$$z^{[l]} = w^{[l]} a^{[l-1]} + b^{[l]}$$

$$a^{[l]} = \sigma(z^{[l]})$$

n_l = nodes layer l

$$w^{[l]} : n_l \times n_{l-1}$$

$$b^{[l]} : n_l \times 1$$

En la red del ejemplo

- PRIMER NODO DEL HIDDEN LAYER

$$z_1^{[1]} = W_1^{[1]T} x + b_1^{[1]}$$

$$a_1^{[1]} = \sigma(z_1^{[1]})$$

⋮

- OUTPUT DEL HIDDEN LAYER

$$\begin{array}{l} 4 \times 1 \\ \swarrow \\ z^{[1]} = W^{[1]} x + b^{[1]} \\ \begin{array}{ccc} 4 \times 1 & 4 \times 3 & 3 \times 1 & 4 \times 1 \end{array} \\ \swarrow \\ a^{[1]} = \sigma(z^{[1]}) \\ \swarrow \\ 4 \times 1 \end{array}$$

- OUTPUT DEL SECOND LAYER

$$\begin{array}{l} z^{[2]} = W^{[2]} a^{[1]} + b^{[2]} \\ \begin{array}{ccc} 1 \times 1 & 1 \times 4 & 4 \times 1 & 1 \times 1 \end{array} \\ \swarrow \\ a^{[2]} = \sigma(z^{[2]}) \end{array}$$

• FUNCIONES DE ACTIVACIÓN $a = g(z)$

(3)

1) Sigmoid

$$g(z) = \frac{1}{1 + e^{-z}} \rightarrow g'(z) = -(1 + e^{-z})^{-2} (-e^{-z})$$
$$= \frac{e^{-z}}{(1 + e^{-z})^2} = \dots = g(z)(1 - g(z))$$

$$g'(z) = a(1 - a)$$

2) Tanh

$$g(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$
$$\vdots$$

$$g'(z) = 1 - (\tanh(z))^2$$
$$= 1 - a^2$$

ENTRENAMIENTO (BACK PROPAGATION)

(4)

El entrenamiento consiste en encontrar los parámetros $\underline{W}^{[L]}$ y $b^{[L]}$

Se tiene una función de costo J que hay que minimizar, por ejemplo:

$$J = \frac{1}{m} \sum_{i=1}^m \text{loss}(\hat{y}^{(i)}, y^{(i)})$$

$i=1 \dots m$: muestras de entrenamiento

$\hat{y}^{(i)}$: output de la red neuronal

$y^{(i)}$: output ideal (supervisado)

Ejemplo: $(\hat{y}^{(i)} - y^{(i)})^2$

o bien

$$-y \log(\hat{y}) - (1-y) \log(1-\hat{y})$$

ALGORITMO DE ENTRENAMIENTO:

0) Se inicializan los parámetros $\underline{W}^{[L]}$ y $b^{[L]}$ con valores random

HASTA CONVERGER → 1) Calcular las predicciones para $i=1 \dots m$
 $z^{[L]} = \underline{W}^{[L]} a^{[L-1]} + b^{[L]}$, $a^{[L]} = \sigma(z^{[L]})$

2) Calcular los derivados:

$$dW^{[L]} = \partial J / \partial W^{[L]}$$


$$db^{[L]} = \partial J / \partial b^{[L]}$$

α : Learning Rate

3) Actualizar parámetros:

$$W^{[L]} = W^{[L]} - \alpha dW^{[L]}, \quad b^{[L]} = b^{[L]} - \alpha db^{[L]}$$

PASS 1: FORWARD PROPAGATION



PASS 2: BACKWARD PROPAGATION

