


Support Vector Machines (SVM : 1996)



¿Cómo elegir l tal que se maximice b ?


l es definido como una recta $g(x) = 0$

donde $g(x) = a_1 x_1 + a_2 x_2 + a_0$

clasificación : $g(x) > 0 \rightarrow$ clase +1
 $g(x) \leq 0 \rightarrow$ clase -1

¿Cómo se calcula esta línea?

• Distancia de un punto x^* a la recta l



$\underline{a} = [a_1, a_2]^T$
 vector perpendicular a la recta \oplus

$$\underline{x}^* = \underline{x}_p + \underline{r}$$

⊕ Sean 2 puntos \underline{x}_A y \underline{x}_B que pertenecen a l

$$a_1 x_{A1} + a_2 x_{A2} + a_0 = 0$$

$$- a_1 x_{B1} + a_2 x_{B2} + a_0 = 0$$

$$[a_1, a_2] (\underline{x}_A - \underline{x}_B) = 0$$

$$\Rightarrow \underline{a} = [a_1, a_2]^T \perp l$$

⊕⊕

$$g(x^*) = a_1(x_{p1} + r_1) + a_2(x_{p2} + r_2) + a_0$$

$$= g(x_p) + \underline{a}^T \underline{r}$$

$$= 0 + r \frac{\underline{a}^T \underline{a}}{\|\underline{a}\|}$$

$$\underline{r} = \underline{r} \frac{\underline{a}}{\|\underline{a}\|} = r \hat{\underline{a}}$$

$$g(\underline{x}^*) = g(\underline{x}_p) + \underline{a}^T \underline{r} \quad \oplus \oplus$$

$$= r \|\underline{a}\| \rightarrow r = \frac{|g(x^*)|}{\|\underline{a}\|}$$

Para encontrar l tal que las distancias de las muestras ~~de~~ de entrenamiento a l sean máximas.

(1): Se puede definir $\frac{|g(x_i^*)|}{\|a\|} > b$ para toda muestra de entrenamiento x_i^* .

Se quiere encontrar a y a_0 tal que se cumpla (1) $\forall i = 1 \dots N$.

Se representa (1) como:

$$(2): \frac{z_i g(x_i)}{\|a\|} > b \quad i = 1 \dots N$$

donde $z_i = \pm 1$ según la clase a que pertenece x_i (± 1) (se elimina el valor absoluto)

Es necesario imponer una restricción adicional a a y a_0 sino escala al infinito.

$$\text{sujeto a } b \|a\| = 1$$

(2) entonces es:

$$z_i g(x_i) \geq 1$$

$$(3) \quad z_i g(x_i) - 1 \geq 0$$

Se quiere entonces minimizar $\|a\|$

maximizar b , entonces equivale a

IDEA:

Hiperplano
de separación:

$$g(\underline{x}) = \underline{a}^T \underline{x} + a_0 = 0$$

Clasificación:

$$\text{sign}(\underline{a}^T \underline{x} + a_0)$$

Distancia de una
muestra \underline{x}_i al
hiperplano

$$r = \frac{|g(\underline{x}_i)|}{\|\underline{a}\|}$$

$$\|\underline{a}\| = \sqrt{a_1^2 + \dots + a_m^2}$$

Se define $z_i \in \{-1, 1\}$ como la clasificación de \underline{x}_i

$$\Rightarrow z_i g(\underline{x}_i) > 0$$

La idea es entonces maximizar b , i.e. minimizar $\|\underline{a}\|$.

Optimización:

$$\text{Minimizar } \frac{1}{2} \|\underline{a}\|^2$$

$$\text{Sujeto a } z_i (\underline{a}^T \underline{x}_i + a_0) \geq 1 \quad i = 1 \dots N$$

Esto se traduce a:

$$(A) \quad J(\underline{a}, \lambda) = \underbrace{\frac{1}{2} \|\underline{a}\|^2}_A - \underbrace{\sum_{i=1}^N \lambda_i [z_i (\underline{a}^T \underline{x}_i + a_0) - 1]}_B \rightarrow \text{Min}$$

A) Se pretende minimizar $\|\underline{a}\|$

B) Se pretende maximizar segundo término

C) Con $\lambda_i > 0$. Se fuerza a clasificar correctamente.

(4) Se puede transformar en (según Kuhn-Tucker)


$$(5) J(\lambda) = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i,j} \lambda_i \lambda_j z_i z_j \underbrace{\underline{x}_i^T \underline{x}_j}_{\langle \underline{x}_i, \underline{x}_j \rangle} \rightarrow \text{Max}$$

Sujeto a $\lambda_i \geq 0$

Al resolver (5) sólo los vectores de soporte, i.e., los puntos que tienen contacto con los bordes del margen tienen $\lambda_i \neq 0$

El resto son muestras irrelevantes

(5) es un problema de optimización \Rightarrow resultado λ_i



Solución:

El hiperplano queda definido como:

$$\hat{g}(\underline{x}) = \hat{\underline{a}}^T \underline{x} + \hat{a}_0$$

donde

$$\hat{\underline{a}} = \sum_{i=1}^N \lambda_i z_i \underline{x}_i$$

(derivando (4) e igualando a 0)



$$\hat{g}(\underline{x}) = \sum_{i=1}^N \lambda_i z_i \underbrace{\underline{x}_i^T \underline{x}}_{\langle \underline{x}_i, \underline{x} \rangle} + \hat{a}_0$$

$$z_i (\hat{\underline{a}}^T \underline{x}_i + \hat{a}_0) = 1, \rightarrow \hat{\underline{a}}^T \underline{x}_i + \hat{a}_0 = 1/z_i = z_i$$

Notas / Notes:

$$\Rightarrow \hat{a}_0 = z_i - \hat{\underline{a}}^T \underline{x}_i \rightarrow \frac{1}{N_{SV}} \sum_{i=1}^{N_{SV}} (z_i - \hat{\underline{a}}^T \underline{x}_i)$$

Support Vector Machines

Transformación
 $h(x)$ (puede ser de \mathbb{R}^m con $m > n$)

La idea es hacer una transformación tal que en el espacio transformado se pueda encontrar un hiperplano.

La línea de separación sería

$$\hat{g}(h(x)) = \hat{a}^T h(x) + \hat{a}_0$$

$$\Rightarrow \hat{g}(x) = \sum_{i=1}^N \lambda_i z_i \langle h(x_i), h(x) \rangle + \hat{a}_0$$

No interesa $h(x)$ sino el producto punto

$$K(x_i, x) = \langle h(x_i), h(x) \rangle$$

→ Función de Kernel.

May utilizadas son:

Polinomio de grado n : $K(x, x') = (1 + \langle x, x' \rangle)^n - \|x - x'\|^2 / c$

Radial Basis : $= \exp$

Neural network : $= \tanh(k_1 \langle x, x' \rangle + k_2)$