


SVM: Support Vector Machine



En SVM se busca una línea de separación l tal que se maximice el margen.

El margen $b = b^+ = b^-$ definido como la distancia perpendicular de la línea l al punto más cercano de cada clase

Definición de l :

$$l: g(\underline{x}) = 0$$

donde

$$g(\underline{x}) = a_1 x_1 + a_2 x_2 + a_0$$


La clasificación de un punto \underline{x} es:

$$\begin{aligned} g(\underline{x}) > 0 &\longrightarrow \text{clase } +1 \\ g(\underline{x}) \leq 0 &\longrightarrow \text{clase } -1 \end{aligned}$$

¿Cómo estimar la recta l ?

- ① \longrightarrow cálculo de distancia de un punto \underline{x}^* a una recta
- ② \longrightarrow planteamiento del problema
- ③ \longrightarrow planteamiento de cómo resolverlo
- ④ \longrightarrow solución

① Distancia de un punto \underline{x}^* a la recta:



$$\underline{x}^* = \underline{x}_p + \underline{r}$$

$$\underline{r} = r \hat{\underline{a}}$$

↳ vector unitario $\perp l$
↳ distancia a l

Se puede demostrar que

$$r = \frac{|g(\underline{x}^*)|}{\|\underline{a}\|}$$

donde $\underline{a} = [a_1, a_2]^T$

② Planteamiento del problema

Para encontrar l , se debe cumplir que las distancias de los puntos de entrenamiento \underline{x}_i a la recta l deban ser $\geq b$:

$$\frac{|g(\underline{x}_i)|}{\|\underline{a}\|} \geq b \text{ para } i=1 \dots N \quad (1)$$

Se debe encontrar a_1, a_2, \dots tal que se cumpla la condición anterior.

Consideramos que $|g(\underline{x}_i)| = z_i g(\underline{x}_i)$

donde $z_i = \pm 1$ si \underline{x}_i pertenece a la clase ± 1 .

(1) se puede escribir como:

$$\frac{\sum_i g(x_i)}{\|\underline{a}\|} \geq b \quad (2)$$

Es necesario imponer una restricción adicional a \underline{a} y a_0 para que no escape al infinito:

$$\text{sueto a } b \|\underline{a}\| = 1$$

Entonces (2) es:

$$\sum_i g(x_i) \geq 1$$

o bien

$$\boxed{\sum_i g(x_i) - 1 \geq 0} \quad (3)$$

Se permire autoras maximizar b , esto equivale a minimizar $\|\underline{a}\|$ tal que se cumpla (3).

PROBLEMA:

Minimizar $\|\underline{a}\|$

Sueto a:

$$\sum_i (\underline{a} \underline{x}_i^T + a_0) - 1 \geq 0 \quad \text{para } i \in [1, N]$$

③ ¿Cómo resolver el problema de optimización?

El problema se traduce a:

$$J(\underline{a}, a_0, \underline{\lambda}) = \underbrace{\frac{1}{2} \|\underline{a}\|^2}_A - \underbrace{\sum_{i=1}^N \lambda_i [z_i (\underline{a}^T \underline{x}_i + a_0) - 1]}_B \rightarrow \min \quad (4)$$

A: Se pretende minimizar $\|\underline{a}\|$

B: Se pretende maximizar segundo término C

C: Con $\lambda_i > 0$ se fuerza a encontrar una solución que clasifique correctamente ($z_i (\underline{a}^T \underline{x}_i + a_0) - 1 > 0$)

Según Kuhn-Tucker, (4) se puede transformar en:


$$J(\underline{\lambda}) = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i,j} \lambda_i \lambda_j z_i z_j \underbrace{\underline{x}_i^T \underline{x}_j}_{\langle \underline{x}_i, \underline{x}_j \rangle} \rightarrow \max \quad (5)$$

Sujeto a $\lambda_i > 0$

$\langle \underline{x}_i, \underline{x}_j \rangle$
producto punto

④ Solución

Al resolver (5), sólo los vectores de soporte, i.e., los puntos \underline{x}_i que tienen contacto en los bordes del margen tienen $\lambda_i \neq 0$. El resto son muestras irrelevantes:



vectores de soporte con $\lambda_i > 0$

En este ejemplo hay 3
vectores de soporte: $N_{SV} = 3$.

Al resolver (5) la solución es λ_i .

Derivando (4), igualando a cero, y conociendo λ_i
se obtiene la solución para \underline{a} :

$$\underline{a} = \sum_{i=1}^N \lambda_i z_i \underline{x}_i$$

$\rightarrow \underline{a} = \sum_{k=1}^{N_{SV}} \lambda_k z_k \underline{x}_k$

(N_{SV} vectores de soporte)

Usando los vectores de soporte se obtiene a_0
ya que para ellos se cumple

$$z_i (\underline{a}^T \underline{x}_i + a_0) - 1 = 0 \quad (1/z_i = z_i)$$

$$\underline{a}^T \underline{x}_i + a_0 = z_i$$

$$\underline{a}_0 = z_i - \underline{a}^T \underline{x}_i$$

\underline{x}_i es
vector de
soporte


El hiperplano queda definido como:

$$g(\underline{x}) = \underline{a}^T \underline{x} + a_0$$

$$g(\underline{x}) = \sum_{i=1}^N \lambda_i z_i \underline{x}_i^T \underline{x} + a_0$$

$\langle \underline{x}_i, \underline{x} \rangle$

⑤ Bonus : líneas de decisión no-lineales.



La línea de separación sería

$$g(\underline{x}) = g(h(\underline{x})) = \underline{a}^T h(\underline{x}) + a_0$$

$$g(\underline{x}) = \sum_{i=1}^N \lambda_i z_i \langle h(\underline{x}_i), h(\underline{x}) \rangle + a_0$$

IMPORTANTE: no interesa $h(\underline{x})$, sino su producto punto \rightarrow Función de kernel

$$\langle h(\underline{x}_i), h(\underline{x}) \rangle = \underbrace{K(\underline{x}_i, \underline{x})}_{\downarrow}$$

Muy utilizadas:

Polinomio grado n : $(1 + \langle \underline{x}_i, \underline{x} \rangle)^n$

Radial Basis : $\exp(-\|\underline{x}_i - \underline{x}\|^2 / c)$

Neural Network : $\tanh(k_1 \langle \underline{x}_i, \underline{x} \rangle + k_2)$